

# Jogadores Tóxicos em Partidas de Jogos *Online*

*Joaquim Neto e Kazuki Yokoyama*

*07 de outubro de 2016*

## Introdução

Juntamente com a popularização das redes sociais na internet, veio a popularização dos jogos *online*. Nesses jogos, o comportamento abusivo de uma parcela dos jogadores é um problema constante. Dentro da comunidade desses jogos, esse tipo de comportamento é denominado tóxico, e pode destruir completamente o esforço de equipe entre os jogadores, arruinando a partida dos jogadores afetados, o que pode levar a uma gama de problemas, desde jogadores desistiram de consumir estes jogos até a problemas psicológicos resultantes do *bullying*, nos casos mais sérios.

Consideramos um jogador tóxico, um jogador que incorre em comportamento abusivo durante o jogo. Neste trabalho, nós consideramos que jogadores tóxicos contaminam o ambiente ao seu redor, tornando o ambiente de jogo pior para todo. Dizemos que ocorre uma contaminação tóxica, quando as ações de um jogador tóxico alteram negativamente o desempenho ou o comportamento de outros jogadores com quem ele interage.

## Objetivos

Pretendemos aqui primeiramente avaliar, através da análise dos dados das partidas e dos jogadores, qual é a extensão da contaminação tóxica aos outros jogadores. Para isso, analisaremos os dados com a finalidade de gerar um modelo para uma métrica de toxicidade. Depois tentaremos descobrir, entre os diferentes tipos de ofensas catalogadas pelo jogo, quais delas geram maior contaminação tóxica. Assim, podemos resumir os objetivos primários do trabalho como sendo

- Avaliar a extensão da contaminação tóxica a outros jogadores a partir dos dados da partida;
- Descobrir que tipos de ofensas geram mais contaminação.

## Objetivos da mineração

- Definir três categorias de jogadores distintas: tóxicos, contaminados e limpos;
- Definir uma métrica do desempenho dos jogadores;
- Mostrar que o jogador tóxico tem uma influência negativa no desempenho dos outros jogadores;
- Criar métrica para quantificar a contaminação dos jogadores considerados contaminados.

A fim de conseguirmos tais objetivos, precisamos primeiramente definir o que caracteriza um jogador tóxico, um jogador contaminado, e um jogador não contaminado (limpo). Após isso, teremos que definir uma métrica que quantifique o desempenho dos jogadores para podermos mostrar que o jogador tóxico exerce uma influência negativa no desempenho de outros jogadores. Finalmente, com essas informações, poderemos criar uma métrica que quantifique o grau da contaminação que o jogador tóxico exerce sobre os contaminados.

## Dados

Nosso trabalho tem como base os dados de partidas do jogo *online League of Legends* - LoL. O *dataset* é formado por denúncias de comportamento tóxico (abusivo) por jogadores do jogo. O *dataset* completo contém

1.46 milhões de casos de denúncias, que podem conter uma ou mais partidas com o jogador denunciado, e no total possui mais de 10 milhões de partidas, tornando-o grande demais para o escopo do nosso trabalho.

Devido a grande extensão dos dados, obtemos uma amostra, com aproximadamente 37 mil partidas. Todas as informações estavam originalmente no formato JSON. Para podermos trabalhar mais facilmente com os dados, escolhemos os atributos que consideramos relevantes ao nosso problema, e os dividimos em dois arquivos CSV: o primeiro contém os dados inerentes à própria partida (`matches.csv`), o outro contém os dados dos jogadores de cada partida (`players.csv`), cujos atributos são descritos abaixo:

### `matches.csv`

- *case* - caso dentro do *dataset* a partida pertence;
- *match* - numeração da partida dentro do caso;
- *premade* - se foi uma partida combinada anteriormente com os outros jogadores do time (1), ou se foi uma partida aonde o jogo combinou os jogadores (0);
- *most.common.offense* - qual foi o tipo de ofensa mais comum do jogador denunciado que foi reportada pelos outros jogadores da partida;
- *reports.allies* - quantidade de denúncias feitas pelo time aliado do jogador denunciado;
- *reports.enemies* - quantidade de denúncias feita pelo time adversário ao jogador denunciado;
- *reports.case* - quantidade total de denúncias em todas as partidas do caso;
- *time.played* - tempo de jogo decorrido nessa partida.

### `players.csv`

- *case* - caso dentro do *dataset* a partida pertence;
- *match* - numeração da partida dentro do caso;
- *relation.offender* - se este jogador está no mesmo time do denunciado (*ally*), em time diferente (*enemy*) ou se é o próprio denunciado (*offender*);
- *champion* - com qual personagem do jogo este jogador está jogando. Note que dois jogadores no mesmo time não podem ter o mesmo personagem;
- *kills* - quantidade de vezes que este jogador matou outros jogadores durante a partida;
- *deaths* - quantidade de vezes que este jogador morreu na partida;
- *assists* - quantidade de vezes que este jogador proveu algum tipo de assistência para o abate de um jogador adversário, mas não realizou o abate ele mesmo;
- *gold* - quantidade de ouro acumulada durante a partida. Normalmente é usado para medir o desempenho de um jogador;
- *outcome* - se este jogador ganhou a partida (*Win*), se ele a perdeu (*Loss*) ou se ele saiu do jogo antes do término (*Leave*).

## Transformação dos dados

Para a nossa análise exploratória, utilizamos a linguagem R. Neste processo de análise exploratória, analisamos e associamos os dados de ambos os *datasets* construídos (*players* e *matches*) de maneiras diferentes, das quais apenas os resultados mais relevantes e os que contribuem para uma compreensão melhor do *dataset* foram reportados aqui. Nossos objetivos nessa etapa são: descobrir possíveis padrões que sejam de futuro interesse e procurar dados que suportem nossas hipóteses.

Outros *datasets* são originados a partir desses dois conjuntos a fim de facilitar a análise. Por exemplo, é possível unir os dois *matches* e *players* através de uma operação de *left join* pelo caso (*case*) e pelo número da partida dentro do caso (*match*). O resultado é um *dataset* mais completo que serve de base para a geração de subconjuntos mais específicos. Abaixo são mostrados as primeiras observações de cada um dos conjuntos originais.

## matches

```
##      case match premade  most.common.offense reports.allies
## 1 400013      0      No Intentionally Feeding              1
## 2 400013      1      No      Verbal Abuse                  1
## 3 400013      2      No      Offensive Language            1
## 4 400013      3      No      Negative Attitude             1
## 5 400626      0      No Intentionally Feeding              3
## 6 400626      1      No      Offensive Language            1
##  reports.enemies reports.case time.played
## 1              0              4             1606
## 2              0              4             2270
## 3              0              4             2055
## 4              0              4             1387
## 5              0              7             1358
## 6              1              7             2519
```

## players

```
##      case match relation.offender  champion kills deaths assists gold
## 1 400013      0      enemy Fiddlesticks      4      2      7 7978
## 2 400013      0      enemy   Veigar          4      1      6 7639
## 3 400013      0      enemy    Ashe          6      1      6 7494
## 4 400013      0      enemy    Amumu          4      0      7 6342
## 5 400013      0      enemy     Lux           7      0      8 7302
## 6 400013      0      offender Tryndamere      0      3      0 4831
##  outcome      KDA
## 1      Win 3.666667
## 2      Win 5.000000
## 3      Win 6.000000
## 4      Win 11.000000
## 5      Win 15.000000
## 6      Loss 0.000000
```

## Análise exploratória dos dados


Abaixo disponibilizamos o resumo de informações de ambos os arquivos obtidos:

### matches.


```
##      most.common.offense  time.played  premade
##  Offensive Language      :11837      Min.    : 378      No :35424
##  Intentionally Feeding: 9444      1st Qu.:1481      Yes: 1694
##  Verbal Abuse             : 6961      Median  :1928
##  Negative Attitude       : 4478      Mean    :1967
##  Assisting Enemy Team    : 3298      3rd Qu.:2363
##  Spamming                 :   875      Max.    :5362
##  (Other)                  :   225
```

### players

```
## relation.offender    kills      deaths      assists
##      :    103   Min.    : 0.000   Min.    : 0.000   Min.    : 0.000
## ally    :143817  1st Qu.: 2.000   1st Qu.: 3.000   1st Qu.: 4.000
## enemy    :179541  Median : 5.000   Median : 5.000   Median : 7.000
## offender: 37117  Mean    : 5.802   Mean    : 5.818   Mean    : 8.402
##          3rd Qu.: 8.000   3rd Qu.: 8.000   3rd Qu.:12.000
##          Max.    :49.000   Max.    :37.000   Max.    :80.000
##      KDA      gold      outcome
## Min.    : 0.000   Min.    : 1027   Leave:  4115
## 1st Qu.: 1.111   1st Qu.: 6647   Loss  :176394
## Median : 2.000   Median : 9178   Win   :180069
## Mean    : 2.793   Mean    : 9551
## 3rd Qu.: 3.500   3rd Qu.:12039
## Max.    :59.000   Max.    :38097
```



Neste gráfico, nós exploramos quais os tipos de comportamento tóxico mais incidentes nas partidas. No eixo X são listados todos os tipos diferentes de denúncias catalogados pelo jogo, e no eixo Y nós mostramos em quantas partidas no *dataset* o jogador ofensor foi denunciado por cada um dos motivos.




A mesma informação é mostrada de forma textual a seguir. A *string* vazia indica que algumas partidas não tiveram denúncias.


```
##
##           Assisting Enemy Team   Inappropriate Name
##           6                     3298                219
## Intentionally Feeding   Negative Attitude   Offensive Language
##           9444           4478                11837
##           Spamming       Verbal Abuse
##           875            6961
```

Este gráfico é bem similar ao anterior. A diferença é que ao invés de ser o número de partidas em que o jogador ofensor foi denunciado por cada tipo de ofensa, nós contamos o número total de denúncias feitas pelos jogadores.

Essa comparação tem como objetivo explicitar que, pela análise exploratória, “*Offensive Language*” é uma ofensa mais grave que as demais, pois ela tem uma média maior de denúncias por partida. Isso pode nos ajudar a fazer uma avaliação futura do modelo de métrica de toxicidade. Também fica evidente que os demais atributos mantêm a mesma proporção.




Fazendo o histograma da variável `time.played`, é fácil ver que há uma anomalia por volta de 1200 e 1300 segundos (~20min). Isso representa que muitas partidas terminam neste período. Supomos que isso ocorra devido a mecânica de rendimento do jogo, onde a partir de 20 minutos de partida um time pode escolher se render e acabar com a partida. Pode-se fazer várias análises futuras de proveito sobre essa anomalia, como por exemplo, descobrir se essas partidas têm uma incidência maior de toxicidade nelas.



Nesta comparação entre a relação com o ofensor (`relation.offender`) e o resultado da partida (`outcome`), nós buscamos saber se existe uma relação entre a presença do ofensor em um time e a taxa de vitórias do time. Aqui encontramos que um time com um jogador tóxico (*ally*), perde consideravelmente mais partidas do que um time sem um jogador tóxico. Isso é um indício claro do que hipotetizamos acima - o jogador tóxico tem uma influência negativa sobre o desempenho de seu time.

## Influência na duração da partida

Existe uma diferença significativa entre o tempo de jogo de aliados do jogador tóxico e seus adversários quando estes ganham uma partida. Os aliados (*ally*) atingem um tempo médio de 2076 segundos, contra 1938 segundos dos adversários (*enemy*). Com isso podemos deduzir que os aliados de um jogador tóxico, mesmo quando ganham uma partida, têm uma dificuldade maior de ganhar, corroborando nossa hipótese de que o jogador tóxico influencia negativamente o desempenho do seu time. Os histogramas da duração da partida nos dois casos são mostrados abaixo.



Podemos testar se a diferença no tempo da partida quando os aliados vencem e quando os adversários vencem é estatisticamente significativa através de um teste  $t$  para duas amostras. Note que não temos motivos para considerar que as variâncias das amostras são iguais.

```
##
##  Welch Two Sample t-test
##
## data:  allies.win$time.played and enemies.win$time.played
## t = 38.278, df = 56551, p-value < 2.2e-16
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  130.2715 144.3324
## sample estimates:
## mean of x mean of y
```

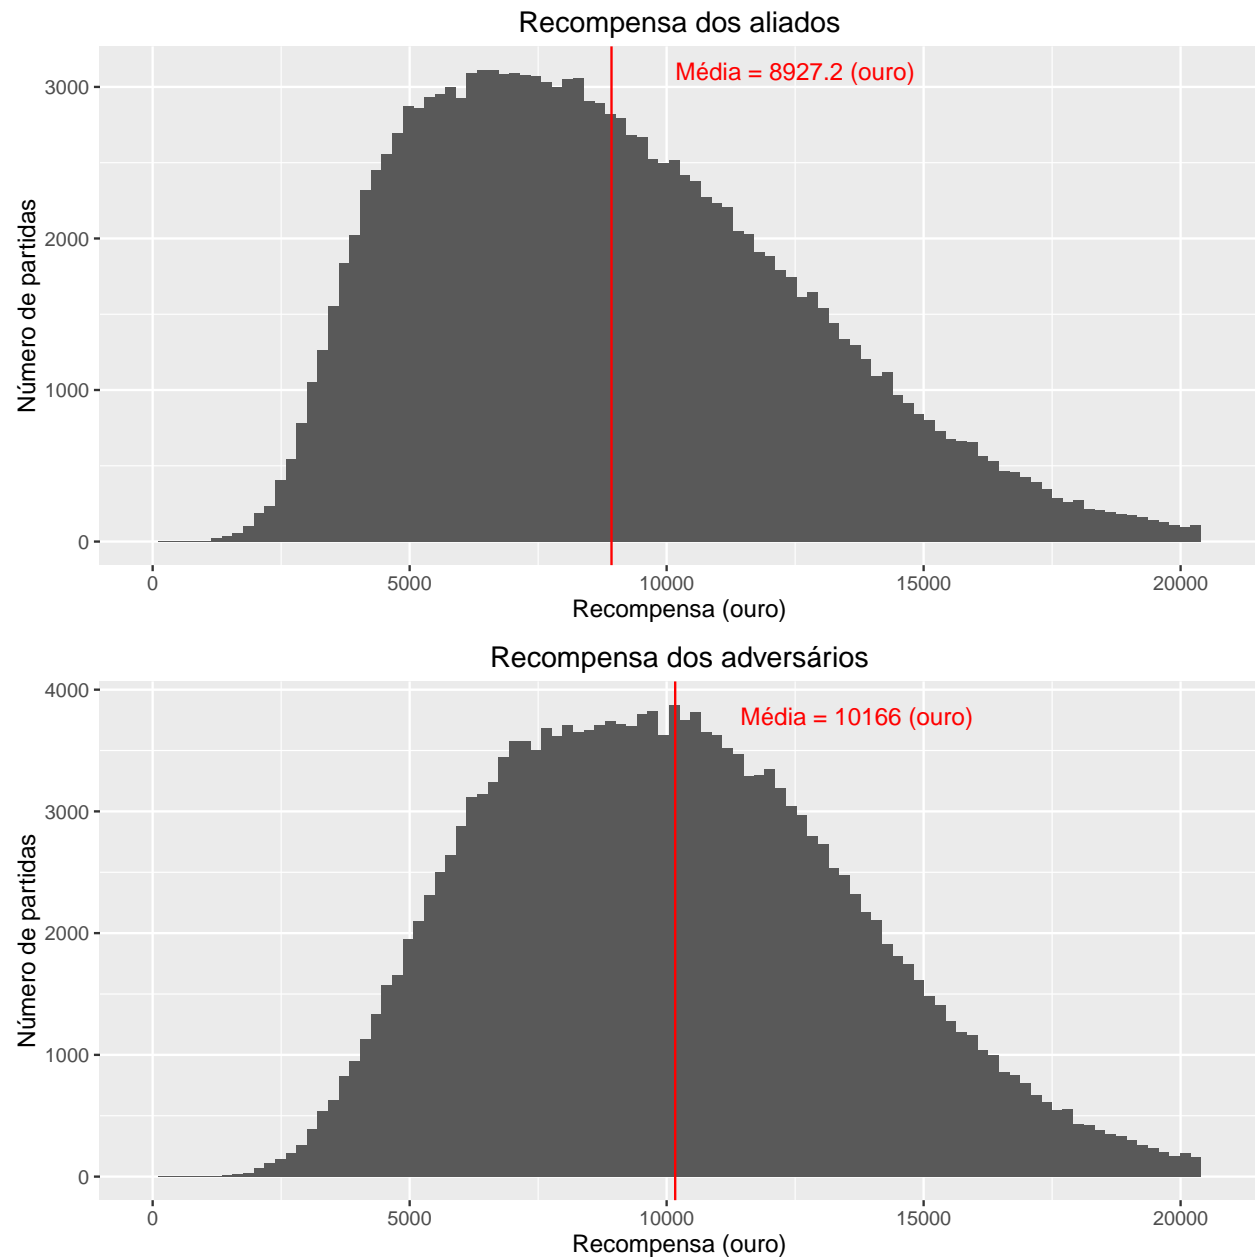


## 2075.500 1938.198

Com um nível de confiança de 5%, rejeitamos a hipótese nula de que as médias são iguais. Assim, podemos concluir que os aliados tendem realmente a demorar mais para a vitória do que os adversários.

## Influência na recompensa

Podemos notar a influência negativa do jogador ofensor no seu time aliado pela menor recompensa que é dada ao seu time em relação ao time adversário. Os jogadores aliados recebem em média 8927 de ouro, enquanto os adversários recebem 10166. Note que consideramos as amostras totais dos aliados e dos adversários independentemente de vitória ou derrota. Abaixo são apresentados os histogramas relativos à recompensa dada aos dois times.



Apesar da média dos adversários ser maior do que dos aliados para as amostras consideradas, não podemos afirmar que esse padrão ocorre em geral. Novamente, a fim de avaliar se a diferença nas duas médias de recompensas é estatisticamente significativa, recorreremos ao teste  $t$  para a média de duas amostras.

```
##
## Welch Two Sample t-test
##
## data: allies$gold and enemies$gold
## t = -93.587, df = 303610, p-value < 2.2e-16
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -1264.963 -1213.066
## sample estimates:
## mean of x mean of y
## 8927.185 10166.199
```

O teste  $t$  mostra que a diferença nas médias é diferente de zero a qualquer nível de confiança prático. Com isso temos mais um motivo para crer que o jogador ofensor exerce uma influência negativa sobre os seus companheiros de time.

## Conclusão

Da análise anterior, podemos concluir que o jogador tóxico influencia negativamente no desempenho da equipe com fortes indícios. Também podemos concluir que os aliados de um jogador tóxico são suas principais ‘vítimas’, assim fazendo sentido considerá-los como jogadores ‘contaminados’. Atualmente, não há fortes evidências da influência do jogador tóxico no desempenho do time adversário, então decidimos considerá-los como jogadores ‘limpos’.

Também a partir da análise, ficou mais claro o que poderia ser obtido através dos dados dispostos e quais objetivos podemos almejar. Também conseguimos confirmar importantes hipóteses iniciais e adquirimos mais confiança de que nossos objetivos finais são possíveis de se conseguir a partir das nossas amostras. Finalmente, gostaríamos de agradecer a (Blackburn et al. 2014) por ter gentilmente cedido o *dataset* utilizado neste trabalho.

## Referências

Jeremy Blackburn e Haewoon Kwak, STFU NOOB! Predicting Crowdsourced Decisions on Toxic Behavior in Online Games, **CoRR**, abs/1404.5905, maio de 2014.